

Technická dokumentácia: KNN

1. Úvod

Tento dokument popisuje implementáciu a fungovanie aplikácie na vizualizáciu klasifikačného algoritmu K-Nearest Neighbors (KNN). Aplikácia umožňuje používateľovi interaktívne meniť parametre modelu, vyberať dátové sady a sledovať rozhodovacie hranice algoritmu v reálnom čase.

2. Použité technológie

Aplikácia je napísaná v jazyku **Python 3** a využíva nasledujúce knižnice:

- **NumPy & Pandas:** Spracovanie dát a numerické výpočty.
- **Matplotlib:** Generovanie grafov a vizualizácia rozhodovacích hraníc.
- **Tkinter:** Tvorba grafického používateľského rozhrania (GUI).
- **Scikit-learn:** Načítanie testovacích dátových sád (Iris, Wine, atď.) a rozdelenie dát na tréningovú a testovaciu množinu.

3. Štruktúra kódu

3.1 Trieda KNN

Implementuje samotný algoritmus "K najbližších susedov" bez použitia externých ML knižníc pre predikciu.

- `fit(X, y)`: Uloží tréningové dáta do pamäte.
- `predict(X_test)`: Pre každý bod v testovacej sade vypočíta Euklidovskú vzdialenosť ku všetkým tréningovým bodom pomocou vektorizovaných operácií, nájde K najbližších a určí výslednú triedu pomocou väčšinového hlasovania (Counter).

3.2 Trieda App

Zodpovedá za grafické rozhranie a logiku prepojenia ovládacích prvkov s vizualizáciou.

- **Načítanie dát:** Podporuje vstavané datasety (Iris, Wine, Breast Cancer, Digits) alebo import vlastného CSV súboru.
- **Režimy zobrazenia:**
 - *Manuálny výber:* Používateľ si zvolí dve konkrétne vlastnosti (osi X a Y).
 - *PCA (Principal Component Analysis):* Redukcia viacerých dimenzií do 2D priestoru pre komplexné datasety, aby ich bolo možné zobraziť v plošnom grafe.
- **Interaktívne prvky:** Slider pre voľbu počtu susedov (K) a slider pre pomer rozdelenia dát (Train/Test split).

4. Funkcie vizualizácie

Aplikácia vykresľuje:

1. **Rozhodovacie oblasti:** Farebné pozadie (contour plot), ktoré indikuje, do ktorej triedy by algoritmus priradil bod v danom mieste.

2. **Trénovacie body:** Zobrazené ako "x", reprezentujú historické dáta použité na učenie modelu.
3. **Testovacie body:** Zobrazené ako farebné krúžky s čiernym okrajom, na ktorých sa overuje presnosť.
4. **Metriky:** V spodnej časti okna sa zobrazuje celková presnosť (accuracy) v percentách a počet správne/nesprávne klasifikovaných bodov.

5. Inštalácia a spustenie

Pre spustenie aplikácie je potrebné mať nainštalované potrebné knižnice:

```
pip install numpy pandas matplotlib scikit-learn
```

Lukáš Kostár